🧠 Introdução ao Aprendizado de Máquina Não Supervisionado

Curso: Aperfeiçoamento Profissional em Programação em Inteligência Artificial Generativa (SENAI-SP)
Unidade / Aula: Aula 01 — Módulo 5: Aprendizado de Máquina Não Supervisionado
Algoritmo Foco: `K-Means` (*Clusterização / Agrupamento*)
Dataset da Prática: `iris.csv` (150 amostras botânicas da Flor Iris)

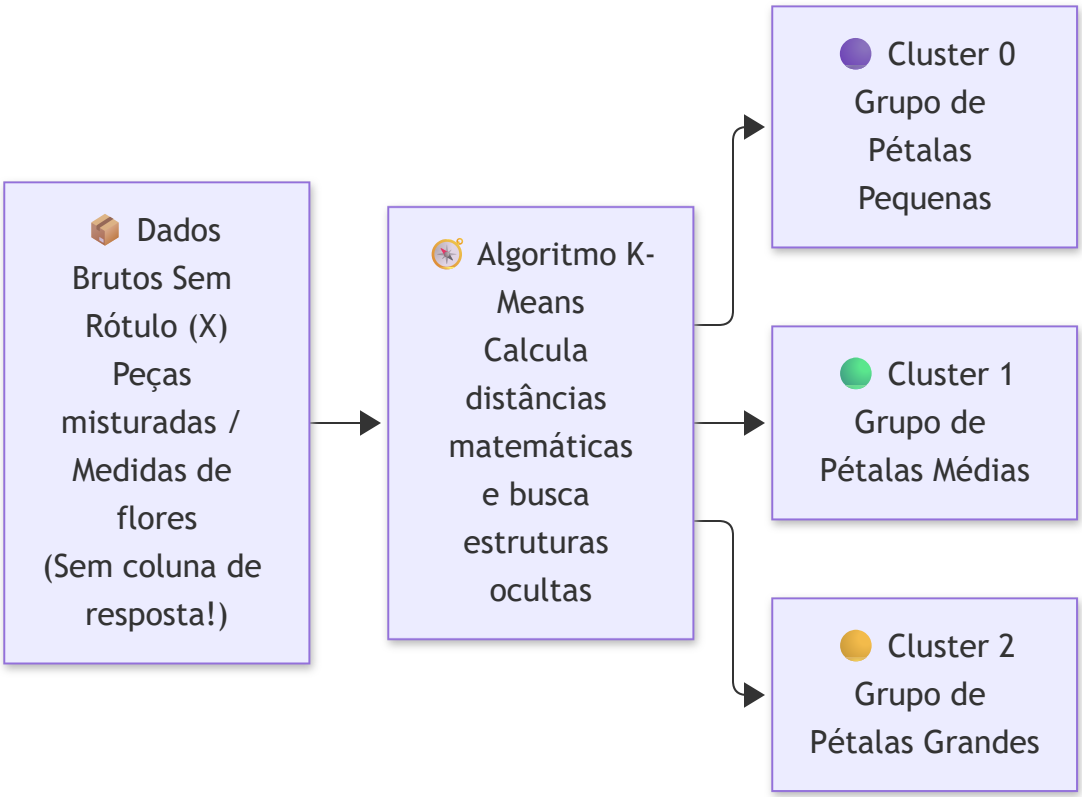
🧩 A Metáfora: A Caixa de Peças sem Manual

> ### 🎲 Imagine o Seguinte Cenário...
>
> Você acabou de receber uma caixa com **centenas de peças de um jogo de tabuleiro totalmente desconhecido**. Você **não tem o manual de instruções** e ninguém lhe disse o nome ou a função de cada peça.
> **O que você faz instintivamente?**
> Naturalmente, você começa a observar as características visuais e a **separar as peças que são parecidas em grupos**:
>
> - *"Essas aqui são redondas e azuis..."*
> - *"Essas outras são quadradas e vermelhas..."*
> - *"Aquelas são compridas e amarelas..."*
>
> **Isso é, na essência, o Aprendizado de Máquina Não Supervisionado!**

1. 🔍 O que é Aprendizado Não Supervisionado?

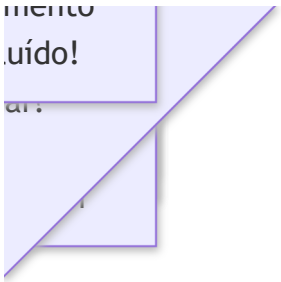
Diferente do **Aprendizado Supervisionado** (onde o modelo aprende com um "professor" e exemplos previamente rotulados, como *"esta foto é um gato"* ou *"esta garrafa é da Casta 1"*), no **Aprendizado Não Supervisionado** o algoritmo trabalha **às cegas**, recebendo dados brutos que **não possuem rótulos, etiquetas ou gabarito (y)**.

- 🎯 **Objetivo Principal:** Descobrir **estruturas ocultas**, semelhanças matemáticas ou padrões naturais dentro dos dados.
- 🗂️ **Técnica Mais Comum: Clusterização (*Clustering* / Agrupamento)** — dividir automaticamente um conjunto de dados em grupos (*clusters*) onde os itens de um mesmo grupo sejam muito parecidos entre si e muito diferentes dos itens de outros grupos.



🔄 Como funciona a Clusterização com K-Means?

O **K-Means** (*K-Médias*) é o algoritmo de agrupamento mais famoso e utilizado na indústria. Ele funciona de maneira iterativa em **5 passos cíclicos**:



1. **Escolha de K:** Definimos quantos grupos queremos que a IA procure (ex.: $k = 3$).
2. **Centroides:** O algoritmo coloca 3 pontos centrais ("âncoras") em posições iniciais no gráfico.

3. **Atribuição:** Cada amostra (flor) calcula sua distância matemática e se conecta ao centroide mais próximo.
4. **Atualização:** O centroide se desloca para o "centro de gravidade" (a média aritmética) de todas as flores que o escolheram.
5. **Repetição:** Os passos 3 e 4 se repetem em ciclos rápidos até que os centroides parem de se mover e os grupos fiquem perfeitamente estáveis!

2. 🧰 Nossas Ferramentas (Ecossistema de Bibliotecas Python)

Para executar essa investigação científica em Python no Google Colab, utilizamos um ecossistema de **6 bibliotecas poderosas**, onde cada uma cumpre um papel específico no projeto:

Biblioteca	Papel e Função no Nosso Projeto
🐼 **Pandas**	Manipulação, leitura do arquivo `.csv` e organização dos dados em tabelas estruturadas (`DataFrames`).
🔢 **NumPy**	Operações matemáticas de alta velocidade e transformação da tabela em matrizes numéricas puras (`arrays`).
📈 **Matplotlib**	Criação da estrutura base de gráficos, títulos, eixos e exibição visual das figuras (`plt.show()`).
🎨 **Seaborn**	Construção de gráficos estatísticos avançados e altamente visuais (`scatterplot` , `regplot` e `pairplot`).
🧠 **Scikit-Learn**	O "cérebro" da operação: fornece o algoritmo `KMeans` , o codificador `LabelEncoder` e as métricas (`silhouette_score` , `accuracy_score`).
📐 **SciPy**	Utilizada para otimização matemática avançada (`linear_sum_assignment`), permitindo alinhar e auditar os rótulos gerados pela IA.

3. 🗺️ O que encontraremos nos Códigos? (A Jornada em 6 Etapas)

O laboratório prático a seguir foi desenhado como uma verdadeira **jornada de Ciência de Dados**. Veja o que faremos passo a passo:

1. 👁️ **Exploração Visual:** Antes de acionar qualquer IA, vamos enxergar as medidas das pétalas e sépalas da flor Iris por meio de gráficos de dispersão (`scatterplot`) e matrizes multivariadas (`pairplot`).
2. 🙈 **O "Cegamento" dos Dados:** Vamos remover propositalmente a coluna `species` (o nome das espécies) usando `.drop("species")` , forçando o modelo a descobrir os grupos sozinho e sem gabarito!
3. ⚙️ **Aplicação do K-Means:** Configuraremos o algoritmo para buscar 3 grupos ocultos (`k = 3`) apenas medindo distâncias geométricas.
4. 🧮 **Mapeamento de Inteligência:** Como o K-Means batiza os grupos apenas com números arbitrários (`Cluster 0` , `Cluster 1` , `Cluster 2`), usaremos a matemática do `SciPy` para conferir se o "Grupo 0" realmente corresponde à espécie biológica certa.
5. 🎯 **Validação de Performance:** Calcularemos a acurácia final para comprovar quão perto da realidade biológica o algoritmo chegou sem nunca ter tido aula de botânica!
6. 📐 **Otimização (O Segredo do K):** E quando estamos no mundo real e **não sabemos** quantos grupos existem? Aprenderemos a descobrir o número ideal de clusters usando duas técnicas definitivas: o **Método do Cotovelo (*Elbow Method*)** e o **Índice de Silhueta (*Silhouette Score*)**.

> 🔥 **Tip**
>
> 💡 **Dica de Aula:** Ao executar cada bloco de código no Google Colab, preste muita atenção em como os dados evoluem de **"informação bruta em tabela"** para **"conhecimento visual intuitivo"** através dos gráficos de `pairplot` !